概率论与信息论 - Homework 2 学习报告

> 目标：按 Homework 2 的 Q1-Q5 学习，并能独立写出每一步。本文以中文为主；全文公式已通过 KaTeX 严格语法检查；阅读时请使用数学公式预览。另附已完成公式排版的离线 HTML 阅读版。数值默认保留约 4 位小数。

阅读说明与资料边界

课程/作业原始内容（本报告的题目、符号和要求以此为准）

- `Lecture 2.pdf`：本课程 Lecture 2，覆盖概率规则、概率密度、变量变换、信息论等。
- `Homework 2.pdf`：本报告中的 Q1-Q5 知识检验及其给定数据均来自该作业。

外部补充（只用于补足直觉、背景和标准表述，不改变课程符号或题意）

- MIT 6.041SC 的条件概率、Bayes 与随机变量课程资源。
- Stanford Statistics 311 的信息论讲义（entropy、KL、mutual information）。
- David J. C. MacKay 的 *Information Theory, Inference, and Learning Algorithms*（信息论与机器学习连接）。

符号约定。 离散变量用 $p(x)$，连续变量用密度 $p_X(x)$。$\log_2$ 的单位是 **bit**，$\ln$ 的单位是 **nat**。必须跟随题目指定的底数；不同底数下的数值不能直接混比。

Q1 - 条件概率、全概率与 Bayes 定理

本题要会什么

给定疾病状态 $C \in \{0,1\}$ 与检测结果 $T \in \{0,1\}$，从 $P(T \mid C)$ 和 $P(C)$ 推出 $P(T)$ 与 $P(C \mid T)$。这是"从原因预测观测"与"看到观测反推原因"的区别。

1. 核心概念与公式

联合概率 $P(A,B)$ 表示 A 和 B 同时发生。条件概率的定义是

$$P(A \mid B) = \frac{P(A,B)}{P(B)}, \qquad P(B) > 0.$$

移项得到**乘法公式**：

$$P(A,B) = P(A \mid B)P(B) = P(B \mid A)P(A).$$

若 $\{B_i\}$ 是互斥且完备的一组情形，则对它们求和得到**全概率公式**：

$$P(A) = \sum_i P(A \mid B_i)P(B_i).$$

把乘法公式的两个写法相等，得到 **Bayes 定理**：

$$P(B \mid A) = \frac{P(A \mid B)P(B)}{P(A)}.$$

在疾病例子中：

$$\underbrace{P(C \mid T)}_{\text{posterior}} = \frac{\overbrace{P(T \mid C)}^{\text{likelihood}}\underbrace{P(C)}_{\text{prior}}}{\underbrace{P(T)}_{\text{evidence}}}.$$

这里的 likelihood 是把 C 看作假设、T 看作观测时的 $P(T \mid C)$。它不是 $P(C \mid T)$。

若 A, B 独立，则

$$P(A,B) = P(A)P(B) \quad \Longleftrightarrow \quad P(A \mid B) = P(A)\ (P(B) > 0).$$

2. 直觉与一个小例子

即使一个检测有很高灵敏度，阳性者也未必大概率患病：还要看疾病是否罕见。设疾病率 1%，灵敏度 99%，假阳性率 5%。在 10,000 人中，约 100 人患病，其中约 99 人阳性；9,900 人未患病，其中约 495 人却阳性。因此阳性人群中真正患病的比例约为 $99/(99+495) \approx 16.7\%$，远不是 99%。这就是**base-rate effect（基率效应）**。

3. 常见误区

- 把 $P(T=1 \mid C=1)$（灵敏度）误读成 $P(C=1 \mid T=1)$（阳性预测值）。条件交换后一般不相等。
- 算 $P(T=1)$ 时漏掉 $C=0$ 的假阳性路径。
- 把"独立"理解为"两个变量取值不同"；独立的定义是一个变量的信息不会改变另一个变量的分布。

4. 知识检验：Homework 2 Q1

已知疾病率为 2%，且

$$P(T=1 \mid C=1) = 0.95, \qquad P(T=1 \mid C=0) = 0.04.$$

要求写出先验与所有 $P(T=t \mid C=c)$，求 $P(T=1)$、$P(C=1 \mid T=1)$、$P(C=1 \mid T=0)$，解释 prior/likelihood/posterior，并说明独立检测为何无信息。

5. 完整答案与步骤

(a)

$$P(C=1) = 0.02, \qquad P(C=0) = 0.98.$$

由每个条件分布的概率和为 1：

$$\begin{aligned} P(T=1 \mid C=1) &= 0.95, \quad P(T=0 \mid C=1) = 0.05, \\ P(T=1 \mid C=0) &= 0.04, \quad P(T=0 \mid C=0) = 0.96. \end{aligned}$$

(b) 阳性可经由"患病且阳性"或"未患病且阳性"发生：

$$
\begin{aligned}
P(T=1) &= P(T=1 \mid C=1)P(C=1) + P(T=1 \mid C=0)P(C=0) \\
&= 0.95(0.02) + 0.04(0.98) \\
&= 0.019 + 0.0392 = \boxed{0.0582}.
\end{aligned}
$$

(c)

$$
\begin{aligned}
P(C=1 \mid T=1) &= \frac{P(T=1 \mid C=1)P(C=1)}{P(T=1)} \\
&= \frac{0.95(0.02)}{0.0582} = \boxed{0.3265 \approx 32.65\%}.
\end{aligned}
$$

(d) 先求 $P(T=0) = 1 - 0.0582 = 0.9418$，再用 Bayes：

$$
P(C=1 \mid T=0) = \frac{0.05(0.02)}{0.9418} = \boxed{0.001062 \approx 0.106\%}.
$$

(e) $P(T=1 \mid C=1) = 0.95$ 是"已患病时检出的机会"，即 **likelihood**； $P(C=1) = 0.02$ 是见到检测前的 **prior**； $P(C=1 \mid T=1) = 0.3265$ 是见到阳性后更新的 **posterior**。后验还受疾病基率与假阳性率影响，所以通常不等于灵敏度。

(f) 若 T 与 C 独立，则 $P(T \mid C) = P(T)$。代入 Bayes：

$$
P(C \mid T) = \frac{P(T \mid C)P(C)}{P(T)} = \frac{P(T)P(C)}{P(T)} = \boxed{P(C)}.
$$

因此看到 T 前后，对 C 的判断不变；该检测不提供疾病状态的信息。

Q2 - 连续随机变量、期望/方差与变量变换

本题要会什么

辨认概率密度（PDF），通过积分求区间概率、期望和方差，并在 $Y = g(X)$ 时正确加入 Jacobian。

1. 核心概念与公式

连续型随机变量的密度 $p_X(x)$ 必须满足

$$
p_X(x) \geq 0, \qquad \int_{-\infty}^{\infty} p_X(x)\,dx = 1.
$$

密度在单点的函数值不是单点概率；连续变量满足 $P(X=x) = 0$。区间概率由面积给出：

$$
P(a < X < b) = \int_a^b p_X(x)\,dx.
$$

若积分存在，

$$
E[X] = \int x p_X(x)\,dx, \qquad E[X^2] = \int x^2 p_X(x)\,dx,
$$

$$
\mathrm{Var}(X) = E[(X - E[X])^2] = E[X^2] - E[X]^2.
$$

对一维、可微且单调的变换 $Y = g(X)$，令 $x = g^{-1}(y)$，则

$$p_Y(y) = p_X\left(g^{-1}(y)\right) \left| \frac{d}{dy} g^{-1}(y) \right|.$$

若变换不一一对应，必须将每个反解分支的密度贡献相加：

$$p_Y(y) = \sum_{x_i : g(x_i) = y} p_X(x_i) \left| \frac{dx_i}{dy} \right|.$$

本题 $X > 0$，所以 $Y = X^2$ 在支持集上单调，不需要多分支求和。

2. 直觉与一个小例子

Jacobian 来自"概率质量守恒"：一个很短的区间 dx 被映射为 dy 时，应有

$$p_X(x)|dx| = p_Y(y)|dy|.$$

例如 $X \sim \mathrm{Unif}(0,1)$、$Y = 2X$。虽然 $p_X(x) = 1$，但 Y 的支持集是 $(0,2)$，且

$$p_Y(y) = 1 \cdot \left| \frac{d(y/2)}{dy} \right| = \frac{1}{2}.$$

若只把 $x = y/2$ 代回 p_X，会错误得到密度 1；其在 $(0,2)$ 上的积分是 2，不是 1。

3. 常见误区

- 用 $p_X(x)$ 代替 $P(X = x)$。连续情形中前者是密度，后者为 0。
- 算方差时写成 $E[X^2] - E[X]$，遗漏 $E[X]$ 的平方。
- 变量变换时直接写 $p_Y(y) = p_X(g^{-1}(y))$，漏掉 Jacobian。
- 没有先写出 Y 的支持集。密度必须在正确的 y 范围外为 0。

4. 知识检验：Homework 2 Q2

$$p_X(x) = \begin{cases} 2x, & 0 < x < 1, \\ 0, & \text{otherwise}, \end{cases} \qquad Y = X^2.$$

验证密度、求 $P(X < 1/2)$、$E[X]$ 与 $\mathrm{Var}(X)$，再完整导出 Y 的密度并解释 Jacobian。

5. 完整答案与步骤

(a) 在 $(0,1)$ 上 $2x > 0$，且

$$\int_{-\infty}^{\infty} p_X(x)\,dx = \int_0^1 2x\,dx = [x^2]_0^1 = 1.$$

故它是合法 PDF。

(b)

$$P\left(X < \frac{1}{2}\right) = \int_0^{1/2} 2x\,dx = [x^2]_0^{1/2} = \boxed{\frac{1}{4}}.$$

(c)

$$E[X] = \int_0^1 x(2x)\,dx = 2\int_0^1 x^2\,dx = \boxed{\frac{2}{3}},$$

$$E[X^2] = \int_0^1 x^2(2x)\,dx = 2\int_0^1 x^3\,dx = \frac{1}{2}.$$

所以

$$\mathrm{Var}(X) = \frac{1}{2} - \left(\frac{2}{3}\right)^2 = \boxed{\frac{1}{18}}.$$

(d) $0 < X < 1$ 且平方在该区间严格递增，故 $\boxed{0 < Y < 1}$。

(e) $y = x^2$ 、 $x > 0$ ，故

$$x = \sqrt{y}, \qquad \left|\frac{dx}{dy}\right| = \boxed{\frac{1}{2\sqrt{y}}}.$$

(f)

$$\begin{aligned} p_Y(y) &= p_X(\sqrt{y})\left|\frac{dx}{dy}\right| \\ &= (2\sqrt{y})\left(\frac{1}{2\sqrt{y}}\right) = 1, \end{aligned}$$

所以

$$p_Y(y) = \begin{cases} 1, & 0 < y < 1, \\ 0, & \text{otherwise}. \end{cases}$$

即 $Y \sim \mathrm{Unif}(0,1)$ 。

(g)

$$\int_{-\infty}^{\infty} p_Y(y)\,dy = \int_0^1 1\,dy = \boxed{1}.$$

(h) 密度的含义是"每单位横轴长度的概率质量"。变换会压缩或拉伸局部长度， $|dx/dy|$ 正是补偿这一尺度变化的 Jacobian，使对应小区间的概率质量相等，并保证新密度仍积分为 1。

Q3 - 信息量、熵与无前缀编码

本题要会什么

区分单个观测的信息量和随机变量的平均不确定性（熵），并解释为什么高概率状态适合短码字。

1. 核心概念与公式

当对数底为 2 时，结果单位为 bit。单个结果 x 的**信息量**（surprisal）是

$$h(x) = -\log_2 p(x).$$

罕见事件 $p(x)$ 小，$h(x)$ 大；必然事件的信息量为 0。独立事件的信息量可加，因为 $-\log[p(x)p(y)] = -\log p(x) - \log p(y)$ 。

熵是信息量的期望，而不是某一个结果的信息量：

$$H(X) = E[h(X)] = -\sum_x p(x)\log_2 p(x).$$

若码字长度为 $\ell(x)$ ，平均码长为

$$L = \sum_x p(x)\ell(x).$$

对于二进制无前缀编码，Shannon 源编码定理给出 $H(X) \le L < H(X) + 1$ （适当编码下）；理想码长的直觉是 $\ell(x) \approx -\log_2 p(x)$ 。

2. 直觉与一个小例子

公平硬币 H 或 T 各以 $1/2$ 发生。每个结果的信息量是 1 bit，故熵也是 1 bit。若硬币 99% 为正面，则"正面"几乎不意外、"反面"很意外；平均看来却更容易预测，所以熵低于 1 bit。

3. 常见误区

- 把 $h(x)$ 当作熵：前者对应一次具体观察，后者是其平均。
- 忘记 $0\log 0$ 按极限定义为 0。
- 看见二进制编码就默认平均码长等于熵；只有特殊情形相等，通常只是接近且不低于熵。
- 用 $\ln$ 却把答案称作 bits。本题要求 $\log_2$ 。

4. 知识检验：Homework 2 Q3

X 的八个状态 (a, b, c, d, e, f, g, h) 的概率依次为

$$\left(\frac{1}{2}, \frac{1}{4}, \frac{1}{8}, \frac{1}{16}, \frac{1}{64}, \frac{1}{64}, \frac{1}{64}, \frac{1}{64}\right).$$

给定码字 $0, 10, 110, 1110, 111100, 111101, 111110, 111111$ 。计算信息量、熵、平均码长，并比较均匀分布情形。

5. 完整答案与步骤

(a) 概率是 2^{-k} 时，信息量就是 k bits。因此

状态	$p(x)$	$h(x) = -\log_2 p(x)$
a	$1/2$	1 bit
b	$1/4$	2 bits
c	$1/8$	3 bits
d	$1/16$	4 bits
e, f, g, h	$1/64$	6 bits each

e, f, g, h 最罕见，信息量最大； a 最常见，信息量最小。概率越小， $-\log_2 p$ 越大。

(b)

$$\begin{aligned} H(X) &= \frac{1}{2}(1) + \frac{1}{4}(2) + \frac{1}{8}(3) + \frac{1}{16}(4) + 4\left(\frac{1}{64}\cdot 6\right) \\ &= 0.5 + 0.5 + 0.375 + 0.25 + 0.375 \\ &= \boxed{2 \text{ bits}}. \end{aligned}$$

每次观察具体是哪个状态尚未确定，所以熵必须按每种结果发生的概率加权平均；它不是任一指定状态（如 a ）的 1 bit 或 e 的 6 bits。

(c) 码长正好是 $(1, 2, 3, 4, 6, 6, 6, 6)$ ，故

$$L = \frac{1}{2}(1) + \frac{1}{4}(2) + \frac{1}{8}(3) + \frac{1}{16}(4) + 4\left(\frac{1}{64}\cdot 6\right) = \boxed{2 \text{ bits}}.$$

(d) $\boxed{L = H(X) = 2 \text{ bits}}$ 。这套码字长度恰好等于 $-\log_2 p(x)$ ，所以达到熵；这不是任意分布或任意可解码码都会有的巧合。

(e) 若八个状态等概率， $p(x) = 1/8$ ：

$$H(X) = -8\left(\frac{1}{8}\log_2\frac{1}{8}\right) = \boxed{3 \text{ bits}}.$$

均匀分布的 3 bits 高于原分布的 2 bits，因为每一个结果都同样难预测；原分布把大量概率集中在 a, b ，不确定性更小。

(f) 高概率状态的 $-\log_2 p(x)$ 小，携带的信息较少；给它较短码字能降低 $L = \sum p(x)\ell(x)$ 。低概率状态可使用长码字，因为它们很少出现，对平均长度影响较小。这正是压缩的核心权衡。

Q4 - 多重度、Stirling 近似与最大熵原则

本题要会什么

从"许多微观排列对应同一宏观计数"理解熵，并用 Stirling 近似得到 Shannon 熵形式；理解在给定均值、方差时高斯分布为何是最大微分熵分布。

1. 核心概念与公式

把 N 个**可区分**物体分入 3 个 bin，若占据数为 (n_1, n_2, n_3) ，则一个 macrostate 对应的微观排列数（**多重度**）是多项式系数：

$$W = \frac{N!}{n_1! n_2! n_3!}.$$

- **Microstate（微观状态）**：哪个具体物体在哪个 bin。
- **Macrostate（宏观状态）**：只记录每个 bin 的数量 (n_1, n_2, n_3) 。

题中定义的每个物体的对数多重度为

$$H_N = \frac{1}{N}\ln W.$$

令 $p_i = n_i/N$，并用 $\ln n! \approx n\ln n - n$，有大 N 近似

$$\frac{1}{N}\ln W \approx -\sum_i p_i \ln p_i.$$

右侧是用自然对数定义的 Shannon entropy，单位为 nat。

连续型的**微分熵**为

$$h(X) = -\int p(x)\ln p(x)\,dx.$$

它与离散熵有重要差异：会依赖坐标尺度，甚至可为负；不要把它直接解释为"压缩所需的 bits"。在固定均值 μ 和方差 σ^2 的连续分布中，高斯分布最大化微分熵，且

$$h\big(N(\mu,\sigma^2)\big) = \frac{1}{2}\ln(2\pi e\sigma^2).$$

2. 直觉与一个小例子

若 12 个编号球放进 3 个盒子，$(4,4,4)$ 只指定数量，却允许许多种"具体哪些球在第一个盒子"的组合；$(10,1,1)$ 的限制则强得多。多重度大的宏观状态不是"每个微观状态更可能"，而是它包含的等可能微观状态更多，因此总概率更大。

3. 常见误区

- 忘记题目说物体可区分：若不可区分，W 的计数不是该多项式系数。
- 把有限 N 的 H_N 与 $H(p)$ 当作严格相等；Stirling 给出的是渐近近似，有限量存在修正项。
- 把"最大熵"理解为"随机挑一个任何时候都最好的分布"。它是在**指定约束集合内**的选择。
- 忘记离散熵和微分熵不同；高斯最大的是固定均值和方差条件下的**微分熵**。

4. 知识检验：Homework 2 Q4

$N = 12$，两种 macrostate 为 $A = (10,1,1)$、$B = (4,4,4)$。计算 W、H_N、$H(p)$，说明 Stirling 极限，判断三类分布中最大熵者，并解释高斯的最大熵含义。

5. 完整答案与步骤

(a)

$$W_A = \frac{12!}{10!1!1!} = 12\times 11 = \boxed{132},$$

$$W_B = \frac{12!}{4!4!4!} = \boxed{34\,650}.$$

因此 B 对应更多微观排列。

(b)

$$H_N(A) = \frac{1}{12}\ln 132 \approx \boxed{0.4069\ \text{nats}},$$

$$H_N(B) = \frac{1}{12}\ln 34650 \approx \boxed{0.8711 \text{ nats}}.$$

故 B 更大，与其较大多重度一致。

(c) 对 A， $p = (5/6, 1/12, 1/12)$：

$$H(p_A) = -\left[\frac{5}{6}\ln\frac{5}{6} + 2\left(\frac{1}{12}\ln\frac{1}{12}\right)\right] = \boxed{0.5661 \text{ nats}}.$$

对 B， $p = (1/3, 1/3, 1/3)$：

$$H(p_B) = -3\left(\frac{1}{3}\ln\frac{1}{3}\right) = \boxed{\ln 3 \approx 1.0986 \text{ nats}}.$$

二者都高于对应的有限 N H_N，但排序相同；差异来自 Stirling 的有限样本修正。

(d)

$$\begin{aligned}\ln W &= \ln N! - \sum_i \ln n_i! \\ &\approx (N\ln N - N) - \sum_i (n_i \ln n_i - n_i) \\ &= N\ln N - \sum_i n_i \ln n_i,\end{aligned}$$

因为 $\sum_i n_i = N$。令 $n_i = Np_i$，则

$$\begin{aligned}\frac{1}{N}\ln W &\approx \ln N - \sum_i p_i \ln(Np_i) \\ &= \ln N - \sum_i p_i(\ln N + \ln p_i) \\ &= \boxed{-\sum_i p_i \ln p_i},\end{aligned}$$

其中使用了 $\sum_i p_i = 1$。误差相对于 N 会消失，因此在大 N 时趋近。

(e) 最大熵者是均匀分布：

$$\boxed{(p_1, p_2, p_3) = (1/3, 1/3, 1/3)}.$$

在只知道三项非负且和为 1 时，任何偏向都增加了额外结构/假设；均匀分布最不偏置，也最难预测。

(f) 最大熵原则说：在所有满足已知约束的分布中，选熵最大的那个，避免擅自引入未被数据支持的结构。只知 μ、σ^2 时，固定这两个量的分布中高斯的微分熵最大。因此选择高斯不是断言真实世界必定高斯，而是说在这些信息之外不额外假定偏度、尖峰、双峰或特定尾部形状的最保守选择。

Q5 - 交叉熵、KL 散度、最大似然与互信息

本题要会什么

把真实分布 p 与模型 q 区分开；掌握 $H(p,q)=H(p)+D_{KL}(p\|q)$，并由此连接最大似然训练。然后从联合分布求边缘、条件熵与互信息。

1. 核心概念与公式

对离散分布 p：

$$H(p)=-\sum_x p(x)\log p(x).$$

以真实分布 p 加权、以模型分布 q 编码的**交叉熵**：

$$H(p,q)=-\sum_x p(x)\log q(x).$$

KL 散度：

$$D_{KL}(p\|q)=\sum_x p(x)\log\frac{p(x)}{q(x)}\geq 0.$$

代数展开立即得到

$$\boxed{H(p,q)=H(p)+D_{KL}(p\|q)}.$$

注意 $D_{KL}(p\|q)$ 通常不对称，且不是严格的距离。若某个 $p(x)>0$ 而 $q(x)=0$，则 $D_{KL}(p\|q)=+\infty$。

对数据 $x_1,\dots,x_n$ 和模型 q_θ，最大似然：

$$\max_\theta\prod_{i=1}^n q_\theta(x_i)\iff\min_\theta\left[-\frac{1}{n}\sum_{i=1}^n\ln q_\theta(x_i)\right].$$

右侧就是对经验数据分布的交叉熵（也称平均 negative log-likelihood）。

对于联合分布：

$$p_X(x)=\sum_y p(x,y),\qquad p(y\mid x)=\frac{p(x,y)}{p_X(x)}.$$

条件熵与互信息（以下若用 $\log_2$ 则单位为 bit）为

$$H(Y\mid X)=-\sum_{x,y}p(x,y)\log_2 p(y\mid x),$$

$$I(X;Y)=H(Y)-H(Y\mid X)=H(X)-H(X\mid Y).$$

等价地，$I(X;Y)=D_{KL}(p(x,y)\|p_X(x)p_Y(y))$，故它非负；独立时为 0。

2. 直觉与一个小例子

若真实标签在 70%/20%/10% 三类间分布，模型把真实常见类的概率压得很低，交叉熵会明显上升，因为 $-\ln q(x)$ 对小 $q(x)$ 惩罚很大。互信息则回答另一个问题：知道 X 后，Y 的不确定性减少多少。若 X 是公平硬币，$Y=X$，则知道 X 后 Y 完全确定，故 $I(X;Y)=1$ bit。

3. 常见误区

- 写交叉熵时把外层权重误写为 $q(x)$；正确的是来自真实/数据分布的 $p(x)$。
- 以为 KL 是对称距离：一般 $D_{KL}(p\|q) \neq D_{KL}(q\|p)$。
- 误称 `maximum likelihood = 最大化概率`；它是最大化"观测数据在参数下的似然"，参数不是随机变量时不是其 posterior。
- 算 $H(Y \mid X)$ 时只算一个 X 值；必须按 $p(x)$ 加权所有条件熵。

4. 知识检验：Homework 2 Q5

Part I（用 $\ln$，单位 nats）

$$p = (0.7, 0.2, 0.1), \quad q_1 = (0.6, 0.25, 0.15), \quad q_2 = (0.4, 0.3, 0.3).$$

计算 $H(p)$、两种交叉熵与 KL，验证恒等式，并说明最小交叉熵和最大似然的关系。

Part II（用 $\log_2$，单位 bits）

联合分布为

	$Y=0$	$Y=1$
$X=0$	0.40	0.10
$X=1$	0.10	0.40

求边缘、$H(Y)$、条件分布、$H(Y \mid X)$、互信息，并解释独立情形。

5. 完整答案与步骤

Part I - 自然对数，单位 nats

(a)

$$\begin{aligned} H(p) &= -[0.7\ln 0.7 + 0.2\ln 0.2 + 0.1\ln 0.1] \\ &= \boxed{0.8018 \text{ nats}}. \end{aligned}$$

(b)

$$\begin{aligned} H(p, q_1) &= -[0.7\ln 0.6 + 0.2\ln 0.25 + 0.1\ln 0.15] \\ &= \boxed{0.8245 \text{ nats}}, \\ H(p, q_2) &= -[0.7\ln 0.4 + 0.2\ln 0.3 + 0.1\ln 0.3] \\ &= \boxed{1.0026 \text{ nats}}. \end{aligned}$$

因此 q_1 的交叉熵更低，按该准则拟合得更好。

(c) 用 $D_{KL}(p\|q) = H(p, q) - H(p)$ 计算（也可逐项计算定义式）：

$$\begin{aligned} D_{KL}(p\|q_1) &= 0.8245488 - 0.8018186 = \boxed{0.02273 \text{ nats}}, \\ D_{KL}(p\|q_2) &= 1.0025954 - 0.8018186 = \boxed{0.20078 \text{ nats}}. \end{aligned}$$

数值验证：

$$0.8018186 + 0.0227303 = 0.8245488 = H(p, q_1),$$

$$0.8018186 + 0.2007768 = 1.0025954 = H(p, q_2).$$

(d) 在优化 q 时， p 是固定的：

$$H(p,q) = \underbrace{H(p)}_{\text{constant in } q} + D_{KL}(p\|q).$$

故两者只差常数，必有

$$\boxed{\arg\min_q H(p,q) = \arg\min_q D_{KL}(p\|q)}.$$

(e) 经验数据的平均负对数似然为

$$-\frac{1}{n}\sum_{i=1}^{n} \ln q_\theta(x_i).$$

它是经验分布 $\hat{p}$ 对 q_θ 的交叉熵 $H(\hat{p}, q_\theta)$ 。因此最大化似然等价于最小化经验交叉熵，也等价于最小化 $D_{KL}(\hat{p}\|q_\theta)$ （在 $\hat{p}$ 固定时）。

Part II - 以 2 为底的对数，单位 bits

(f)

$$p_X(0) = 0.40 + 0.10 = 0.5, \qquad p_X(1) = 0.10 + 0.40 = 0.5.$$

同理

$$p_Y(0) = 0.40 + 0.10 = 0.5, \qquad p_Y(1) = 0.10 + 0.40 = 0.5.$$

所以 $\boxed{p(X) = (0.5, 0.5),\ p(Y) = (0.5, 0.5)}$ 。

(g)

$$H(Y) = -2\left(\frac{1}{2}\log_2\frac{1}{2}\right) = \boxed{1 \text{ bit}}.$$

(h)

$$p(Y \mid X=0) = (0.40/0.5,\ 0.10/0.5) = \boxed{(0.8, 0.2)},$$

$$p(Y \mid X=1) = (0.10/0.5,\ 0.40/0.5) = \boxed{(0.2, 0.8)}.$$

两个条件分布的熵相同：

$$H(Y \mid X=0) = H(Y \mid X=1) = -[0.8\log_2 0.8 + 0.2\log_2 0.2] \approx 0.7219.$$

又 $P(X=0) = P(X=1) = 0.5$ ，故

$$H(Y \mid X) = 0.5(0.7219) + 0.5(0.7219) = \boxed{0.7219 \text{ bits}}.$$

(i)

$$I(X;Y) = H(Y) - H(Y \mid X) = 1 - 0.7219281 = \boxed{0.2781 \text{ bits}}.$$

(j) 在未观察 X 时，对 Y 的不确定性是 1 bit；观察 X 后尚余约 0.7219 bits。因此观察 X 平均带来 0.2781 bits 信息：

$$\boxed{\text{information gained} = \text{uncertainty before} - \text{uncertainty after}}.$$

(k) 若独立，$p(y \mid x) = p(y)$，所以知道 X 不改变 Y 的不确定性：$H(Y \mid X) = H(Y)$。因而

$$\boxed{I(X;Y) = 0}.$$

作业前速查表

看到的任务	首选公式 / 动作
给 $P(T \mid C)$、$P(C)$，求 $P(T)$	$P(T) = \sum_c P(T \mid C = c)P(C = c)$
已知观测，反推原因	$P(C \mid T) = P(T \mid C)P(C)/P(T)$
连续变量区间概率	$\int_a^b p_X(x)\,dx$
方差	先算 $E[X]$、$E[X^2]$，再用 $E[X^2] - E[X]^2$
$Y = g(X)$	先写 Y 支持集、求反函数和 Jacobian；非一一映射则按分支求和
单个结果"多意外"	$h(x) = -\log p(x)$
平均不确定性	$H(X) = -\sum p \log p$
模型与真实分布的编码损失	$H(p,q) = -\sum p \log q$
比较模型贴近真实分布	$D_{KL}(p\|q) = H(p,q) - H(p)$
观察 X 对 Y 的价值	$I(X;Y) = H(Y) - H(Y \mid X)$

最后自检清单

- ☐ 我写清楚了条件符号 $\mid$ 左右各是谁吗?
- ☐ 我求连续变量概率时用的是积分而非密度函数值吗?
- ☐ 我做变量变换时写了支持集和 Jacobian 吗?
- ☐ 我是否按题目使用了正确的对数底（bit 或 nat）?
- ☐ 我把 p （真实/经验分布）与 q （模型分布）区分开了吗?
- ☐ 我求条件熵时是否对所有 x 以 $p(x)$ 加权?

来源与延伸阅读

课程/作业原始资料

1. 本课程 `Lecture 2.pdf`（本报告用作课程定义、符号和讲授范围的依据）。
2. 本课程 `Homework 2.pdf`（本报告 Q1-Q5 的题目、参数与要求的依据）。

外部补充资料

1. MIT OpenCourseWare, 6.041SC: Probabilistic Systems Analysis and Applied Probability - Resource Index：条件概率、Bayes、独立性、随机变量与导出分布的系统课程资源。
2. John Duchi, *Lecture Notes on Statistics and Information Theory*（Stanford）：entropy、KL divergence、mutual information 与条件版本的严谨讲义。
3. David J. C. MacKay, *Information Theory, Inference, and Learning Algorithms*：将信息论、推断和机器学习联系起来的开放教材。

> 延伸阅读中的公式采用各自的符号与对数约定；提交本作业时优先遵从题面：Q3 与 Q5 Part II 使用 $\log_2$，Q4 与 Q5 Part I 使用 $\ln$。