Lecture2 概率论汇总 | Probability Summary

> 来源：香港中文大学 Huichen Zhu Lecture 2 Probability 公式支持 LaTeX 渲染，例题沿用 PPT 原始案例，中英对照

目录 Table of Contents

1. 机器学习引入概率论：不确定性 | Motivation: Probability in Machine Learning
2. 概率基本法则 | The Rules of Probability
3. 概率密度 | Probability Densities
4. 期望、方差、协方差 | Expectation, Variance and Covariance
5. 高斯分布 | The Gaussian Distribution
6. 密度的变量变换 | Transformation of Densities
7. 信息论 | Information Theory

---

1 机器学习引入概率论：不确定性 | Motivation: Probability in Machine Learning

传统确定性机器学习模型 | Deterministic view of machine learning

$$x \to \hat{y}$$

- x：观测特征 observed features
- $\hat{y}$：点预测 point-wise prediction

概率视角机器学习模型 | Probabilistic view

$$x \to p(y \mid x)$$

> 模型不只是输出决策，而是量化决策的不确定性。 The model is not merely making a decision; it is quantifying uncertainty about that decision.

两类不确定性 Two Sources of Uncertainty

认知不确定性 Epistemic Uncertainty

- 中文：由知识有限带来的不确定性；可通过增加训练数据降低。
- English: Uncertainty due to limited knowledge; can generally be reduced by collecting more data.
- 成因 Cause：有限训练数据 finite training data；模型学习不充分 imperfectly learned model
- 通俗理解：**我们了解得还不够多 We do not know enough yet.**

偶然不确定性 Aleatoric Uncertainty

- 中文：来自数据本身固有波动、观测不完备；即使有无穷多训练数据依然存在。
- English: Uncertainty arising from intrinsic variability or incomplete observations; may remain even with unlimited training data.

- 成因 Cause：测量噪声 noisy measurements；存在未观测的相关变量 unobserved relevant variables
- 通俗理解：**观测输入没有包含全部信息 The observed input does not contain all the information.**

> 案例：脑部肿瘤 MRI 检测 Brain-Tumor Example 仅使用图像：$p(\text{brain tumor} \mid \text{image})$ 仍有很大不确定性 增加活检信息：$p(\text{brain tumor} \mid \text{image}, \text{biopsy})$，不确定性大幅下降 更丰富的观测可以降低偶然不确定性。Richer information can reduce uncertainty.

> 关键区分 Key distinction 对同一批有限特征做更多观测，**无法消除偶然不确定性**； 但是收集更多维度、不同类型测量，有时可以降低偶然不确定性。

点预测 vs 分布预测 Point Prediction vs. Distribution Prediction

- 点预测 Point prediction：$\hat{y} = 10$，**无法提供任何不确定信息**
- 概率分布预测 Distribution prediction：$Y \mid X = x \sim \mathcal{N}(10, 2^2)$
  - 既给出中心预测值 the central prediction
  - 同时给出预测的不确定程度 how uncertain that prediction is

概率机器学习核心对象：条件分布 $p(y \mid x)$

概率在机器学习各处的应用 Probability Appears Across Machine Learning

1. 分类 Classification：$P(Y = k \mid X = x)$，描述类别归属的不确定性 uncertainty about class membership
2. 回归 Regression：$p(y \mid x)$，描述连续输出的不确定性 uncertainty about a continuous outcome
3. 生成建模 Generative modeling：$p(x)$ or $p(x \mid z)$，描述数据生成方式 how data are generated
4. 参数不确定性 Parameter uncertainty：贝叶斯机器学习，参数后验 $p(\theta \mid \mathcal{D})$
5. 预测 Predictive distribution：结合参数与观测的不确定性，$p(y_{\text{new}} \mid x_{\text{new}}, \mathcal{D})$

> 概率的作用 Why Probability? 概率提供一套自洽框架：
>
> 1. 表示不确定性 representing uncertainty
> 2. 融合不同来源信息 combining different sources of information
> 3. 获取新信息后更新不确定性 updating uncertainty when new information becomes available
> 4. 信息不完备时做预测与决策 making predictions and decisions when information is incomplete 概率是描述不确定性的数学语言 Probability is the mathematical language of uncertainty.

---

2 概率基本法则 | The Rules of Probability

> PPT 案例：癌症筛查医学示例 A Medical Screening Example $p(\text{cancer}) = 0.01$
>
> - 无癌症人群，3% 检测阳性 false-positive rate = 0.03
> - 患癌人群，10% 检测阴性 false-negative rate = 0.10

定义随机变量：

$$C = \begin{cases} 1, & \text{cancer 患癌} \\ 0, & \text{no cancer 无癌症} \end{cases}, \quad T = \begin{cases} 1, & \text{positive test 检测阳性} \\ 0, & \text{negative test 检测阴性} \end{cases}$$

已知条件：

$$p(C=1)=0.01,\quad p(C=0)=0.99$$
$$p(T=1\mid C=1)=0.90,\quad p(T=0\mid C=1)=0.10$$
$$p(T=1\mid C=0)=0.03,\quad p(T=0\mid C=0)=0.97$$

问题 1：随机抽一个人，检测阳性的总概率？ Question 1: Probability that the test result is positive for a randomly selected person?

$$\begin{aligned}p(T=1)&=p(T=1\mid C=1)\,p(C=1)+p(T=1\mid C=0)\,p(C=0)\\&=0.90\times 0.01+0.03\times 0.99=0.0387\end{aligned}$$

问题 2：检测结果为阳性时，此人实际患癌的概率？ Question 2: If test positive, probability of actually having cancer?

$$\begin{aligned}p(C=1\mid T=1)&=\frac{p(T=1\mid C=1)\,p(C=1)}{p(T=1)}\\&=\frac{0.90\times 0.01}{0.0387}=\frac{90}{387}\approx 0.23\end{aligned}$$

> 检测阳性，实际患癌概率仅约 23%。可以用 10000 人列联表直观理解。

	T=1 阳性	T=0 阴性	Total
C=1 患癌	90	10	100
C=0 无癌	297	9603	9900
Total	387	9613	10000

> - 先验 Prior：观测之前 $p(C)$
> - 后验 Posterior：观测检测结果之后更新得到 $p(C\mid T)$ 贝叶斯定理将先验知识与新证据结合 Bayes' theorem combines prior information with new evidence.

离散随机变量基础定义 Basic definition for discrete RV

- 联合概率 Joint probability $p(X,Y)$：X 与 Y 同时发生的概率 probability of X and Y
- 条件概率 Conditional probability $p(Y\mid X)$：已知 X 发生，Y 发生的概率 probability of Y given X
- 边缘概率 Marginal probability $p(X)$：消去 Y 变量后 X 单独的概率

求和规则 Sum Rule

$$p(X)=\sum_{Y}p(X,Y)$$

> 对不需要的变量做求和，得到边缘分布 Sum over alternatives.

乘积规则 Product Rule

$$p(X,Y)=p(Y\mid X)\,p(X)$$

> 沿着条件做乘法 Multiply along conditions.

贝叶斯定理 Bayes' Theorem

由乘积规则变形：

$$p(Y \mid X) = \frac{p(X \mid Y)\, p(Y)}{p(X)}$$

分母归一化常数，使用求和规则展开：

$$p(X) = \sum_{Y'} p(X \mid Y')\, p(Y')$$

独立变量 Independent Variables

X, Y 独立的充要条件：

$$p(X, Y) = p(X)\, p(Y) \iff p(Y \mid X) = p(Y)$$

> 若测试 T 和癌症 C 互相独立，则 $p(C \mid T) = p(C)$，检测完全不能提供信息，测试无效。

> ⚠️ 重要区分：独立一定协方差为 0；协方差为 0 **不一定独立**。 Important distinction: Independence implies zero covariance, but zero covariance does not generally imply independence.

---

3 概率密度 | Probability Densities

离散变量 Discrete RV：可以讨论单点概率 $P(X = x)$。 连续变量 Continuous RV：单点概率 $P(X = x) = 0$；概率定义在区间上 Probability assigned to interval.

概率密度函数 PDF $p(x)$

小区间近似 Approximation for small width Δ:

$$P(x < X < x + \Delta) \approx p(x)\, \Delta$$

区间 (a, b) 的概率 Probability over interval:

$$P(a < X < b) = \int_a^b p(x)\, dx$$

合法 PDF 的两个条件 Valid probability density:

$$p(x) \geq 0, \quad \int_{-\infty}^{+\infty} p(x)\, dx = 1$$

> ⚠️ 重点提醒 Important note：密度值可以大于 1！只有积分之后的概率必须落在 $[0, 1]$。 Density is not probability. The value $p(x)$ may exceed 1. Only integrated probability must lie between 0 and 1.

累积分布函数 CDF Cumulative Distribution Function

$$P(z) = P(X \leq z) = \int_{-\infty}^{z} p(x)\, dx$$

若 CDF 可导 If P is differentiable：

$$p(x) = \frac{dP(x)}{dx}$$

混合分布（离散+连续）Mixed joint density

C 离散，X 连续 Discrete C, continuous X

$$p(c, x) = P(C = c)\, p(x \mid C = c)$$

> 经验口诀 Rule of thumb：对离散变量求和 sum over discrete variables，对连续变量积分 integrate over continuous variables.

连续版本三大概率规则 Probability rules for continuous variables

$$\begin{aligned}
\text{求和规则 Sum rule：} \quad & p(x) = \int p(x, y)\, dy \\
\text{乘积规则 Product rule：} \quad & p(x, y) = p(y \mid x)\, p(x) \\
\text{贝叶斯定理 Bayes' theorem：} \quad & p(y \mid x) = \frac{p(x \mid y)\, p(y)}{\int p(x \mid y')\, p(y')\, dy'}
\end{aligned}$$

常用密度 Common densities

1. 均匀分布 Uniform distribution

$$p(x) = \begin{cases} \dfrac{1}{d - c}, & c < x < d \\ 0, & \text{otherwise} \end{cases}$$

2. 指数分布 Exponential distribution

常用于非负量，等待时间 nonnegative quantities such as waiting times

$$p(x \mid \lambda) = \lambda e^{-\lambda x}, \quad x \geq 0$$

3. 拉普拉斯分布 Laplace distribution

尖峰重尾 sharp peak and heavier tails than Gaussian

$$p(x \mid \mu, \gamma) = \frac{1}{2\gamma} \exp\left(-\frac{|x - \mu|}{\gamma}\right)$$

4. 狄拉克 δ 函数 Dirac-delta function

全部概率集中在单点 all probability mass concentrated at μ

$$p(x \mid \mu) = \delta(x - \mu), \quad \int_{-\infty}^{\infty} \delta(x - \mu)\, dx = 1$$

筛选性质 Sifting property：$\int f(x)\, \delta(x - \mu)\, dx = f(\mu)$

5. 经验分布 Empirical distribution

样本 $\mathcal{D} = \{x_1, \ldots, x_N\}$

$$p(x \mid \mathcal{D}) = \frac{1}{N} \sum_{n=1}^{N} \delta(x - x_n)$$

每个观测分配权重 $1/N$，不需要参数假设 places weight $1/N$ at each observed data point.

> PPT 快速练习题 Quick Check
>
> $$p(x) = \begin{cases} 2x, & 0 < x < 1 \\ 0, & \text{otherwise} \end{cases}$$
>
> $$P\left(X < \frac{1}{2}\right) = \int_0^{1/2} 2x \, dx = \frac{1}{4}, \quad \mathbb{E}[X] = \int_0^1 x \cdot 2x \, dx = \frac{2}{3}$$

---

4 期望、方差、协方差 | Expectation, Variance and Covariance

期望 Expectation

概率加权平均 probability-weighted average

离散 Discrete：

$$\mathbb{E}[f(X)] = \sum_x p(x) \, f(x)$$

连续 Continuous：

$$\mathbb{E}[f(X)] = \int p(x) \, f(x) \, dx$$

样本估计（大数定律）Estimating expectation from data

$$\mathbb{E}[f(X)] \approx \frac{1}{N} \sum_{n=1}^{N} f(x_n)$$

当样本趋向无穷大时等式成立，approximation exact as $N \to \infty$.

条件期望 Conditional expectation

$$\mathbb{E}_X[f(X) \mid Y = y] = \int p(x \mid y) \, f(x) \, dx$$

方差 Variance

衡量围绕均值的离散程度 spread around the mean

$$\mathrm{Var}[f(X)] = \mathbb{E}\left[\big(f(X) - \mathbb{E}[f(X)]\big)^2\right]$$

计算恒等式 Computational identity：

$$\mathrm{Var}[f(X)] = \mathbb{E}\left[f(X)^2\right] - \big(\mathbb{E}[f(X)]\big)^2$$

协方差 Covariance

衡量变量共同变化趋势 tendency to vary together

$$\mathrm{Cov}[X, Y] = \mathbb{E}\left[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])\right] = \mathbb{E}[XY] - \mathbb{E}[X]\,\mathbb{E}[Y]$$

- $\mathrm{Cov} > 0$：两者倾向同时变大；large values tend to occur together
- $\mathrm{Cov} < 0$：一个变大另一个倾向变小；one large when other small
- $\mathrm{Cov} = 0$：无线性共变，不代表独立 no linear co-variation, not imply independence

协方差矩阵 Covariance Matrices

针对随机向量 for random vectors

$$\mathrm{Cov}[\boldsymbol{X}] = \mathbb{E}\left[(\boldsymbol{X} - \mathbb{E}[\boldsymbol{X}])(\boldsymbol{X} - \mathbb{E}[\boldsymbol{X}])^\top\right]$$

对角线 diagonal：各分量方差 component variances；非对角线 off-diagonal：两两协方差 pairwise covariances.

---

5 高斯分布 | The Gaussian Distribution

一维高斯概率密度 One-dimensional Gaussian density

$$\mathcal{N}\left(x \mid \mu, \sigma^2\right) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left\{-\frac{(x-\mu)^2}{2\sigma^2}\right\}$$

参数 Parameters

- μ：均值 mean
- σ^2：方差 variance
- $\sigma = \sqrt{\sigma^2}$：标准差 standard deviation
- $\beta = \dfrac{1}{\sigma^2}$：精度 precision

高斯分布性质 Gaussian properties

$$\mathbb{E}[X] = \mu, \quad \mathrm{Var}(X) = \sigma^2$$

高斯分布满足：均值 = 中位数 = 众数 mean = median = mode = μ

高斯极大似然估计 Maximum Likelihood Estimation for Gaussian

i.i.d 样本 $\mathcal{D} = \{x_1, \ldots, x_N\},\ x_n \sim \mathcal{N}(\mu, \sigma^2)$

似然函数 Likelihood function：

$$p(\mathcal{D} \mid \mu, \sigma^2) = \prod_{n=1}^{N} \mathcal{N}(x_n \mid \mu, \sigma^2)$$

对数似然 Log-likelihood（乘积转求和，避免数值下溢）

$$\log p(\mathcal{D} \mid \mu, \sigma^2) = -\frac{1}{2\sigma^2} \sum_{n=1}^{N} (x_n - \mu)^2 - \frac{N}{2} \log \sigma^2 - \frac{N}{2} \log(2\pi)$$

MLE 估计结果：

$$\mu_{\mathrm{ML}} = \frac{1}{N} \sum_{n=1}^{N} x_n \quad (\text{样本均值 sample mean，无偏 unbiased})$$

$$\sigma^2_{\mathrm{ML}} = \frac{1}{N} \sum_{n=1}^{N} (x_n - \mu_{\mathrm{ML}})^2$$

> ⚠️ MLE 方差是有偏估计 MLE variance is biased
>
> $$\mathbb{E}\left[\sigma^2_{\mathrm{ML}}\right] = \frac{N-1}{N}\sigma^2$$
>
> 无偏样本方差 Unbiased sample variance
>
> $$\tilde{\sigma}^2 = \frac{1}{N-1} \sum_{n=1}^{N} (x_n - \mu_{\mathrm{ML}})^2$$

> PPT 快速练习题 Quick Check 样本 $\mathcal{D} = \{1, 2, 3\}$
>
> $$\mu_{\mathrm{ML}} = \frac{1+2+3}{3} = 2$$
>
> $$\sigma^2_{\mathrm{ML}} = \frac{1}{3}\left[(1-2)^2 + (2-2)^2 + (3-2)^2\right] = \frac{2}{3}$$
>
> 无偏方差 unbiased variance：$\tilde{\sigma}^2 = \dfrac{2}{3-1} = 1$

概率视角回归 Probabilistic view of regression

假设输出带有高斯噪声 target with Gaussian noise

$$p(t \mid x, w, \sigma^2) = \mathcal{N}\left(t \mid y(x, w), \sigma^2\right)$$

等价形式 Equivalent form

$$t = y(x, w) + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \sigma^2)$$

> 重要结论 Important conclusion：平方误差损失不是人为选择；它等价于高斯噪声假设下的负对数似然。 Sum-of-squares loss is not arbitrary choice: it is negative log-likelihood implied by Gaussian observation noise.

新的预测为完整分布 New prediction is distribution:

$$p(t \mid x, w_{\mathrm{ML}}, \sigma^2_{\mathrm{ML}}) = \mathcal{N}\left(t \mid y(x, w_{\mathrm{ML}}), \sigma^2_{\mathrm{ML}}\right)$$

均值给出点预测，方差量化预测不确定性。

---

6 密度的变量变换 | Transformation of Densities

> 背景：标准化流 Normalizing Flow 生成模型数学基础 foundation of normalizing-flow models 已知 X 的密度，变换 $x = g(y)$，求 Y 的密度。 ⚠️ 密度不能直接代入函数，变换拉伸压缩区间，需要雅可比修正因子保证概率质量守恒。

一维变量替换公式 One-dimensional change-of-variables

$$p_y(y) = p_x\big(g(y)\big) \left| \frac{dg(y)}{dy} \right|$$

- $|\cdot|$ 绝对值：保证因子非负 absolute value ensures non-negative factor
- 导数代表局部区间缩放倍数 derivative measures local change in scale

使用逆变换的等价写法 Equivalent form with inverse transform $y = f(x),\ x = f^{-1}(y)$

$$p_y(y) = p_x\left(f^{-1}(y)\right) \left| \frac{d\, f^{-1}(y)}{dy} \right|$$

> PPT 快速练习题 Quick Check $X \sim \mathrm{Uniform}(0,3),\ Y = \dfrac{X}{3}$，求 Y 的密度。 $x = 3y,\ \left|\dfrac{dx}{dy}\right| = 3$
>
> $$p_y(y) = p_x(3y) \cdot \left|\frac{dx}{dy}\right| = \frac{1}{3} \times 3 = 1, \quad 0 < y < 1$$
>
> 得到 $Y \sim \mathrm{Uniform}(0,1)$。

> 直观理解 intuition：
>
> - 变换拉伸区间 → 密度下降 stretch interval → lower density
> - 变换压缩区间 → 密度上升 compress interval → higher density

多维变量替换 Multivariate change-of-variables

$\boldsymbol{x} = g(\boldsymbol{y}),\ \boldsymbol{x}, \boldsymbol{y} \in \mathbb{R}^D$

$$p_{\boldsymbol{y}}(\boldsymbol{y}) = p_{\boldsymbol{x}}\big(g(\boldsymbol{y})\big) \cdot \left|\det J_g(\boldsymbol{y})\right|$$

J 雅可比矩阵 Jacobian matrix，全部一阶偏导数：

$$J = \frac{\partial \boldsymbol{x}}{\partial \boldsymbol{y}^\top} = \begin{pmatrix} \dfrac{\partial g_1}{\partial y_1} & \cdots & \dfrac{\partial g_1}{\partial y_D} \\ \vdots & \ddots & \vdots \\ \dfrac{\partial g_D}{\partial y_1} & \cdots & \dfrac{\partial g_D}{\partial y_D} \end{pmatrix}$$

$|\det J|$：局部体积缩放倍数 absolute determinant measures local volume change.

标准化流 Normalizing Flows

一连串可逆变换 sequence of invertible transformations:

$$z_0 \to z_1 \to \cdots \to z_K = x$$

每一步 $z_k = f_k(z_{k-1})$

$$\log p_k(z_k) = \log p_{k-1}(z_{k-1}) - \log \left| \det \frac{\partial f_k}{\partial z_{k-1}^\top} \right|$$

累积得到最终对数密度：

$$\log p_x(x) = \log p_0(z_0) - \sum_{k=1}^{K} \log |\det J_k|$$

---

7 信息论 | Information Theory

> 信息论量化不确定性被消除时获得多少信息。Quantifies how much information is revealed when uncertainty is reduced.

自信息 Information Content

观测事件 x 得到的信息量：

$$h(x) = -\log_b p(x)$$

- $\log_2$，单位 bit 比特
- $\ln$，单位 nat 纳特

性质 Properties

1. 低概率事件，信息量更大；Unlikely event provides more information
2. 确定事件信息量为 0；Certain event provides no information
3. 独立事件信息量可加；Independent events provide additive information

离散香农熵 Discrete Shannon Entropy

熵是随机变量的期望自信息 entropy is expected information content

$$H[X] = -\sum_x p(x) \log p(x)$$

约定 $0 \log 0 = 0$。熵代表观测 X 之前的平均不确定性 average uncertainty before observing X。

伯努利分布熵 Bernoulli variable $X \sim \text{Bernoulli}(\mu)$

$$H[X] = -\mu \log_2 \mu - (1-\mu) \log_2 (1-\mu)$$

当 $\mu = 0.5$，熵取最大值，不确定性最高。

微分熵 Differential Entropy（连续随机变量）

$$H[X] = -\int p(x)\log p(x)\,dx$$

⚠️ 微分熵特点 Important properties of differential entropy

1. 可以为负数 can be negative
2. 依赖坐标尺度 depends on measurement scale
3. 不能直接代表编码比特 does not equal number of bits

> 重要定理 Theorem：给定均值与方差，**高斯分布拥有最大微分熵**。 Among all continuous distributions with specified mean and variance, Gaussian has largest differential entropy.

$$H[\mathcal{N}(\mu,\sigma^2)] = \frac{1}{2}\big(1+\ln(2\pi\sigma^2)\big) = \frac{1}{2}\ln\left(2\pi e\,\sigma^2\right)$$

交叉熵与 KL 散度 Cross-Entropy & Kullback-Leibler divergence

$p(x)$ 真实分布 true distribution，$q(x)$ 近似分布 approximation

交叉熵 Cross-entropy

$$H(p,q) = -\int p(x)\log q(x)\,dx$$

KL 散度（相对熵）KL-divergence

$$D_{\mathrm{KL}}(p\|q) = \int p(x)\log\frac{p(x)}{q(x)}\,dx = H(p,q) - H(p)$$

KL 核心性质：

1. $D_{\mathrm{KL}}(p\|q) \geq 0$；当且仅当 $p(x)=q(x)$ 几乎处处成立取等。
2. **KL 非对称** $D_{\mathrm{KL}}(p\|q) \neq D_{\mathrm{KL}}(q\|p)$，**不是距离 not a metric**。
3. 极大似然等价最小化前向 KL 散度 Maximum likelihood minimizes $D_{\mathrm{KL}}(p_{\mathrm{data}}\|q_\theta)$。

条件熵、联合熵 Conditional Entropy & Joint Entropy

$$H[Y\mid X] = -\iint p(x,y)\log p(y\mid x)\,dx\,dy$$

熵链式法则 Chain rule for entropy

$$H[X,Y] = H[X] + H[Y\mid X]$$

> X, Y 联合不确定性 = X 的不确定性 + 已知 X 条件下 Y 剩余的不确定性。

互信息 Mutual Information

衡量观测 X 之后，Y 不确定性下降多少，捕捉统计依赖（包含非线性依赖）

$$I[X;Y] = D_{\mathrm{KL}}\big(p(x,y)\,\|\,p(x)p(y)\big) = \iint p(x,y)\log\frac{p(x,y)}{p(x)p(y)}\,dx\,dy$$

等价形式 Equivalent expressions:

$$I[X;Y] = H[X] - H[X \mid Y] = H[Y] - H[Y \mid X]$$

- $I[X;Y] \geq 0$
- 当且仅当 X, Y 统计独立，$I[X;Y] = 0$

> PPT 案例：
>
> 1. 完全观测 Perfect observation：$Y = X$，$I[X;Y] = 1\ \text{bit}$
> 2. 完全独立 Independent observation：Y 独立于 X，$I[X;Y] = 0$

> 互信息优点：可以捕捉非线性依赖，不限于线性相关。 Mutual information depends on statistical dependence, including nonlinear dependence. It is not restricted to linear association.

附录：易混淆概念速查表 Appendix: Quick reference table

概念 Concept	**核心要点 Key takeaway**
概率 vs 概率密度 Probability vs PDF	概率 $0 \leq P \leq 1$；密度可大于 1，只有积分得到概率
认知/偶然不确定性 Epistemic / Aleatoric	认知：增加数据可降低；偶然：任务固有噪声，靠增加特征维度缓解
MLE 高斯方差有偏 Biased Gaussian MLE variance	估计均值消耗 1 自由度；无偏估计分母使用 $N - 1$
变量变换 Change-of-variable	必须乘雅可比行列式绝对值；忽略则破坏概率归一
KL 散度 Kullback-Leibler	非对称，不是距离；极大似然等价最小化正向 KL
微分熵 Differential entropy	可负数，依赖坐标尺度，不可直接当作编码比特；离散熵恒 ≥ 0